DEEP SCHOOL

лекция

Инференс-сервер своими руками: воркшоп по BentoML

спикер

Старобыховская Анастасия → Лаборатория ИИИ (ЕУ СПб)

Проверка связи

Напишите в чат +, если хорошо видно и слышно

Нюансы

1.5 часа

продолжительность встречи

вопросы

задавайте в чат, ответим в конце

Для тех, кто будет до конца

Name	Last commit
src	added gitignore
.gitignore	
README.md	
req.txt	

Точки управления

- @bentoml.service
  - Строгая привязка к сервису
  - Управление ресурсами
  - Runtime окружение
- bentofile.yaml
  - От окружения, до системных бибилиотек
  - Фиксирует полную спецификацию для reproducible сборки
- Переменные окружения
  - Разделяет код от конфигурации (API keys, DB URLs, thresholds)

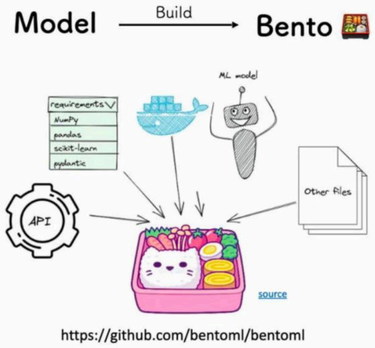

- → презентация лекции
- → репозиторий с кодом

Анастасия Старобыховская

Руководитель Лаборатории «Искусство и ИИ»

1. работала CV-инженером в областях медицины, автономных автомобилей и металлургии
2. руководит лабораторией и проектами в сфере применения ИИ в исследованиях музейных предметов и предметов искусства
3. ~5 лет создаёт и преподаёт образовательные программы ИТМО и Европейский университет
4. спикер DeepSchool

Что нас ждет

1. Обсудим проблему
2. Рассмотрим варианты решений
3. Поглядим на BentoML и не только
4. Пойдём писать код и паковать контейнеры

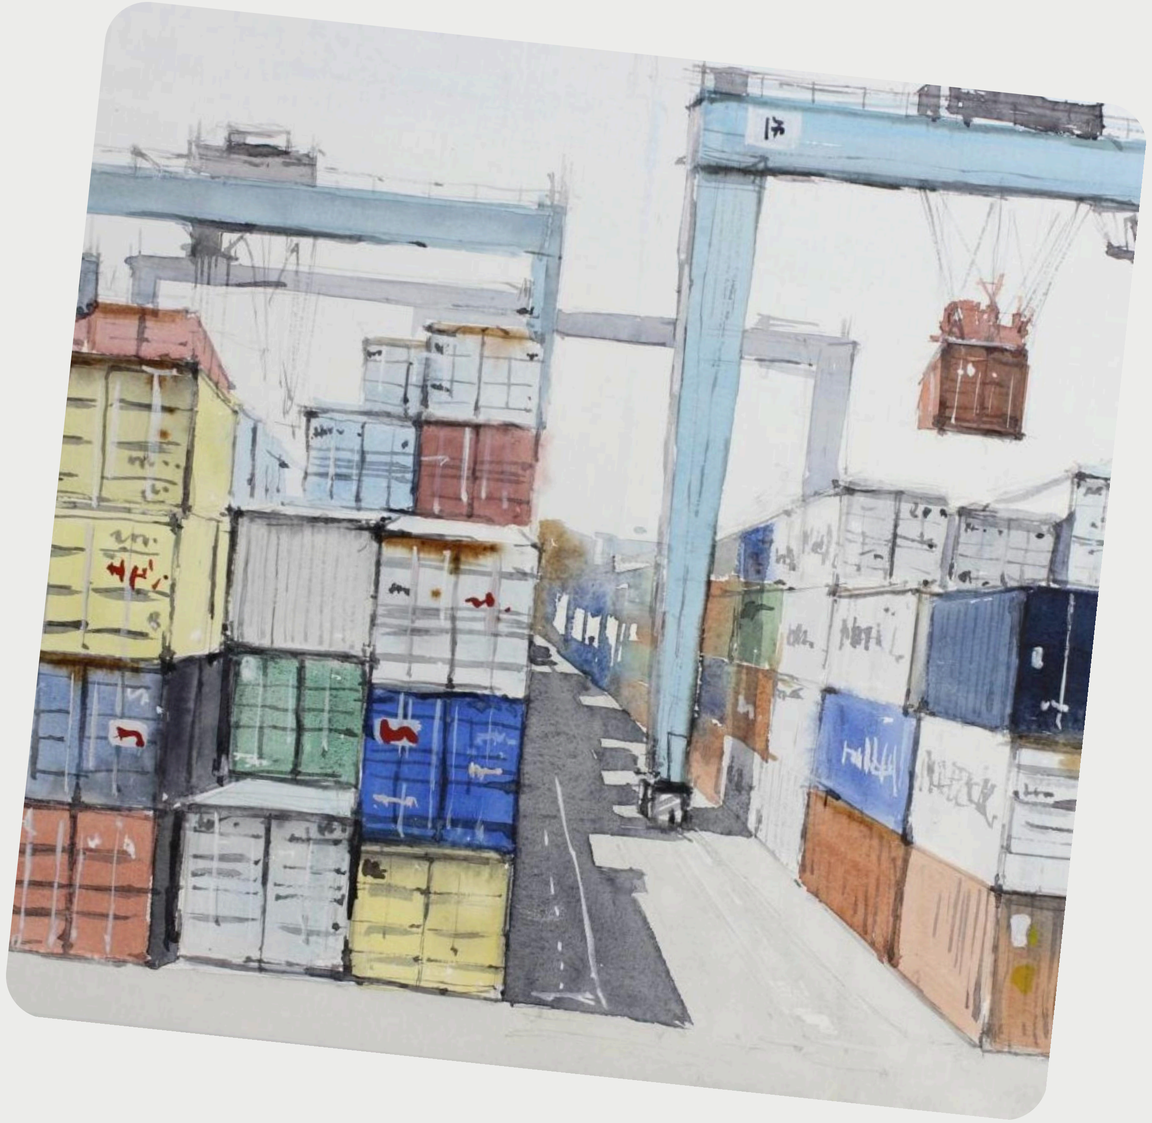

Жизненный цикл модели

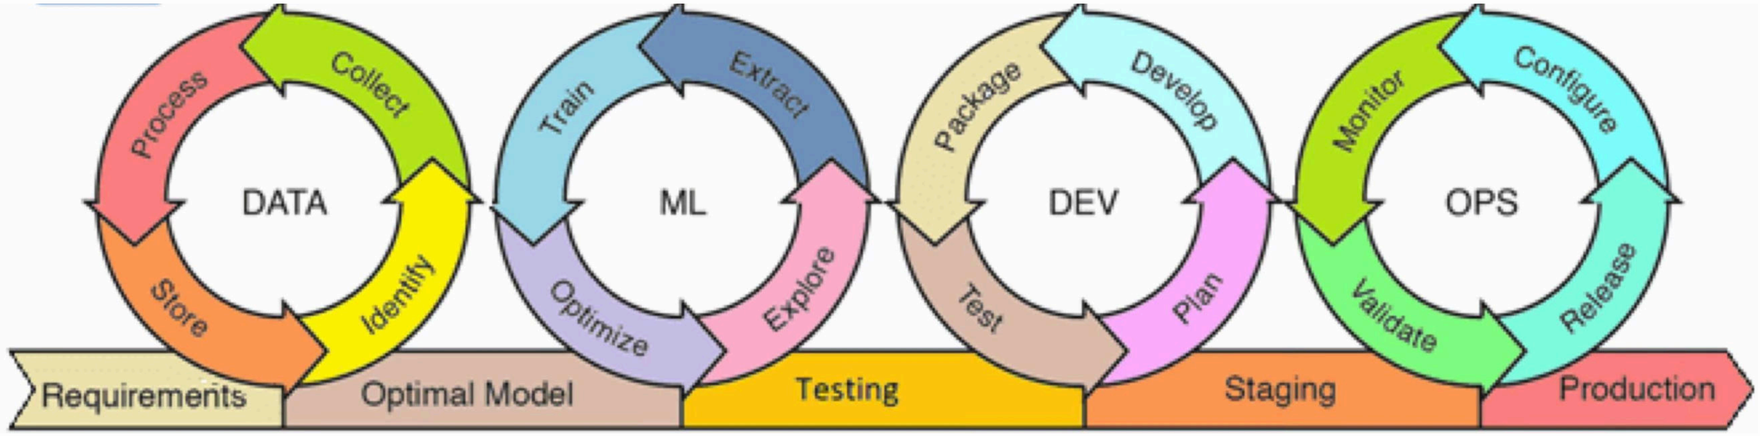

Жизненный цикл модели

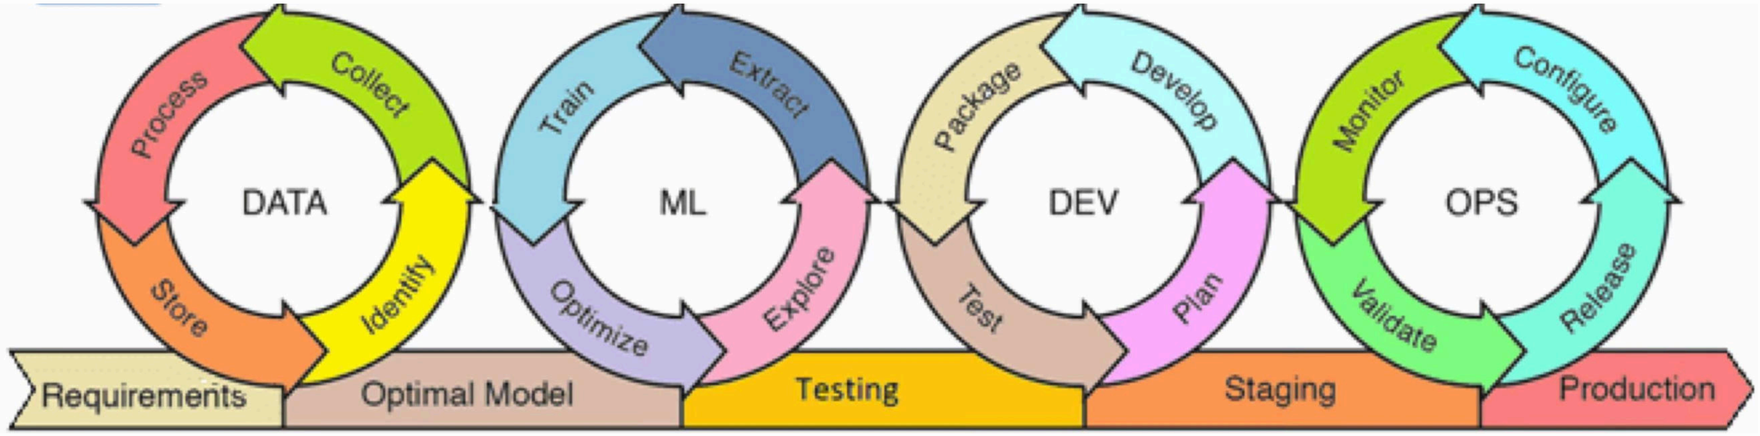

Исследуем
и готовим данные

Алгоритмы,
модельки,
счастье радость

А дальше все
как в тумане...

Я обучил модель А дальше что?

БАЗОВЫЙ МИНИМУМ

1. Я отдаю ноутбук/код разработчикам
2. Я пишу в бекенде свой код

Я обучил модель А дальше что?

1	*Я отдаю ноутбук/код разработчикам*
2	*Я пишу в бекенде свой код*
3	Я отдаю докер с кодом и окружением, его дальше встраивают

Основные беды

- Встраивание кода модели в backend — опасно
- Сложно поддерживать, конфликты зависимостей
- Хранение модели в файлах / S3 / HuggingFace
- Нет стандартизированного API, каждый backend пишет свой код
- Flask / FastAPI ручной сервис
- Много шаблонного кода, трудно поддерживать и масштабировать

Я обучил модель А дальше что?

РОСКОШНЫЙ МАКСИМУМ ?!

1	*Я отдаю ноутбук/код разработчикам*
2	*Я пишу в бекенде свой код*
3	*Я отдаю докер с кодом и окружением, его дальше встраивают*
4	У меня настроен mlflow/kuberflow/... магия происходит без меня
5	BentoML/FastAPI наше
6	Seldon, у нас все серьезно
7	Triton/TorchServe/...

BentoML

- Фреймворк для упаковки ML/AI моделей в инференс-сервисы
- Позволяет:
  - Сохранять модель с её окружением
  - Версионировать модели
  - Поднимать REST или gRPC сервер
  - Легко обращаться к модели извне
  - Управлять основными настройками через конфиг
  - Поддерживает PyTorch, TensorFlow, HuggingFace, Diffusers и др.

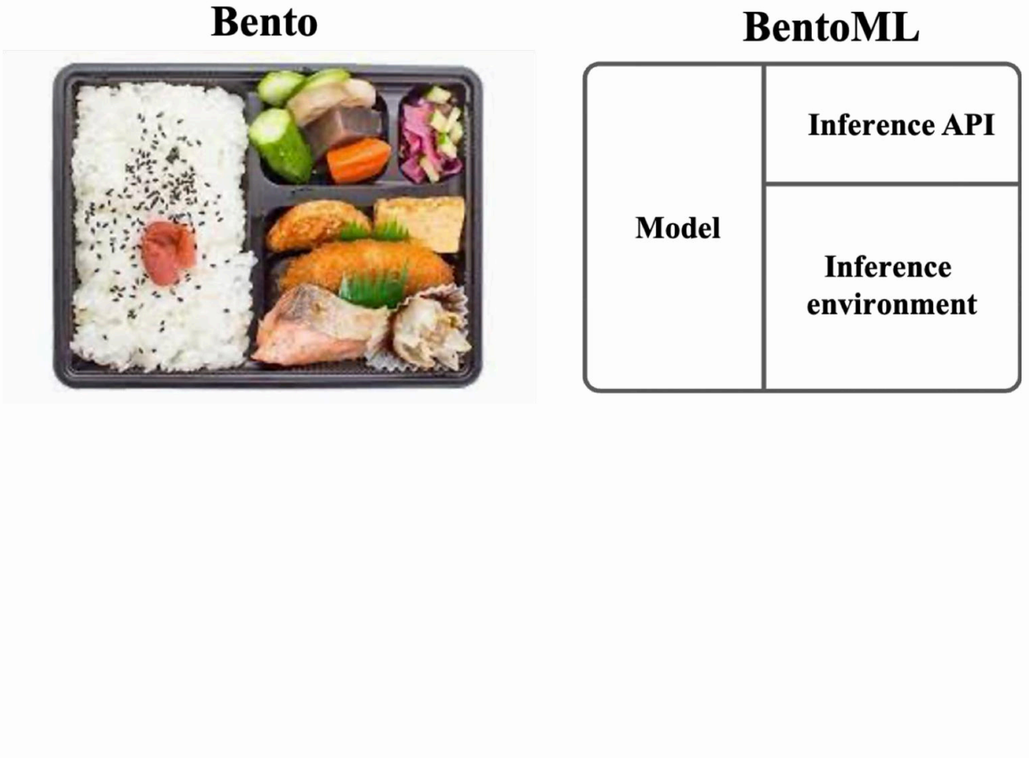

BentoML

- Backend получает готовый сервис
- Минимальные действия:
  - Запустить сервис: bentoml serve <bento> или поднять контейнер
  - Сделать HTTP-запросы к API
  - Backend не трогает код модели, не устанавливает зависимости

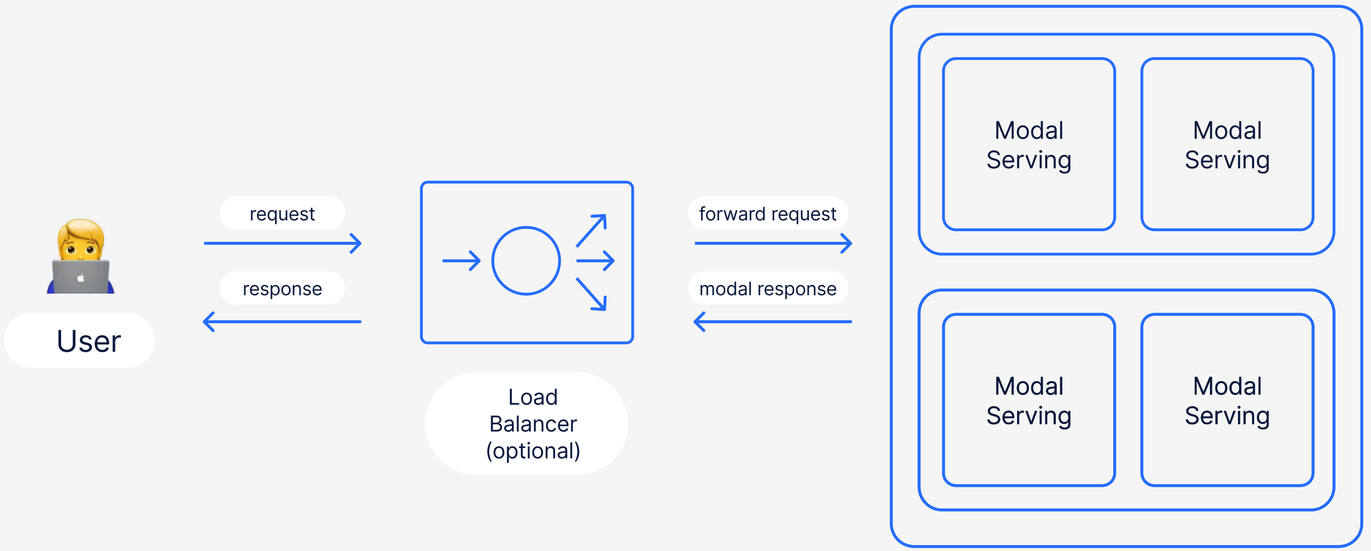

Не bento земля едина

→ FastAPI / Flask
- Более гибкие, но низкоуровневые
- Зависимости и контоль вычислительных ресурсов на вас

→ TorchServe
- Только PyTorch
- Сложнее настроить кастомные API и постобработку

→ Triton Inference Server (NVIDIA)
- Сложнее конфигурировать и деплоить
- Не интуитивный Python API
- Меньше гибкости в кастомной логике API

→ И другие

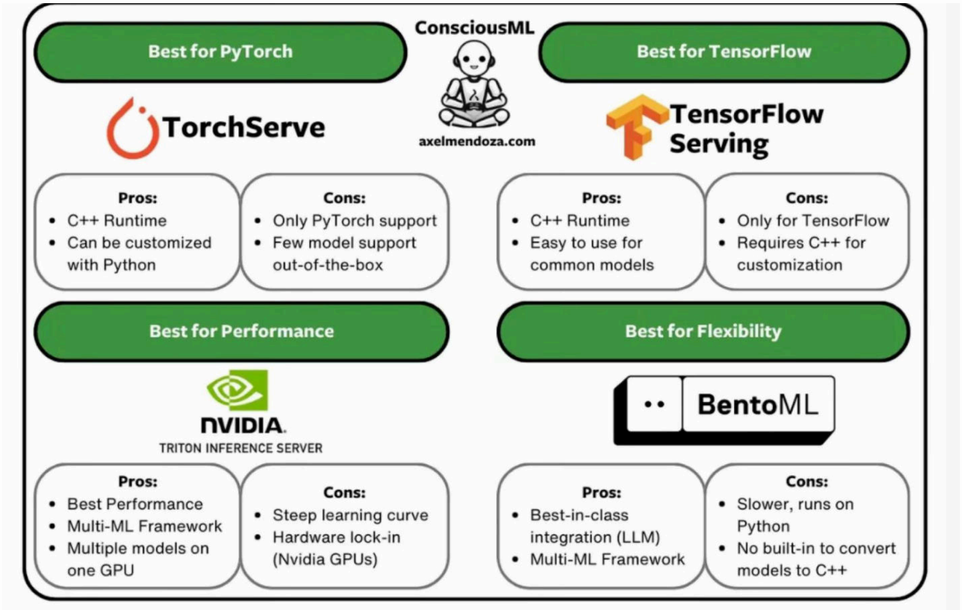

www.axelmendoza.com/posts/best-model-serving-runtimes↗

Однако, bentoml

Что нам понадобится

- Моделька
- Окружение
- IDE и Python
- Запущенный демон Docker

Принцип работы

- Создаем модуль сервиса
- Создаем класс сервиса и настраиваем
- Помечаем методы, которые будут «ручками»
- Уточняем конфигурации
- Запускаем

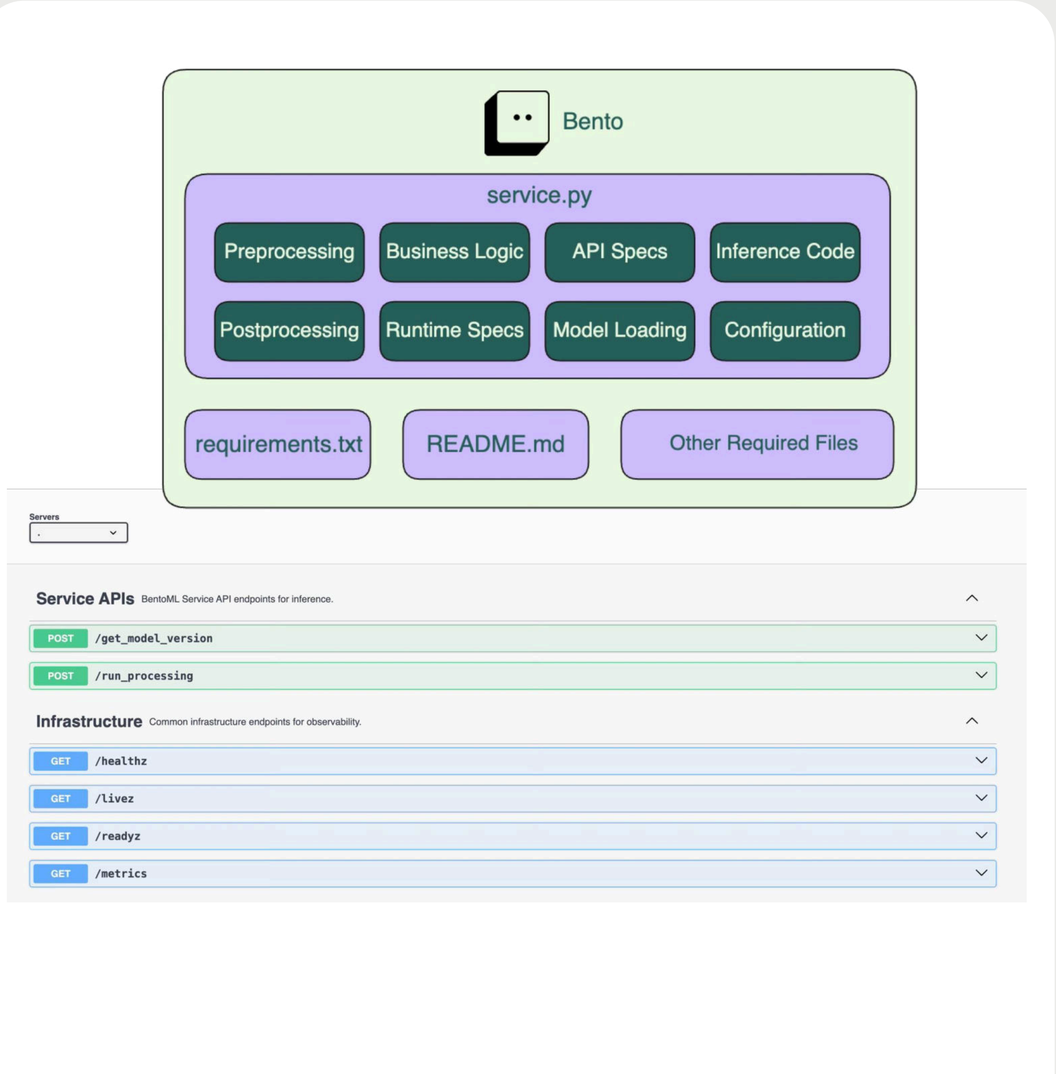

Точки управления

- @bentoml.service
  - Строгая привязка к сервису
  - Управление ресурсами
  - Runtime окружение
- bentofile.yaml
  - От окружения, до системных бибилиотек
  - Фиксирует полную спецификацию для reproducible сборки
- Переменные окружения
  - Разделяет код от конфигурации (API keys, DB URLs, thresholds)

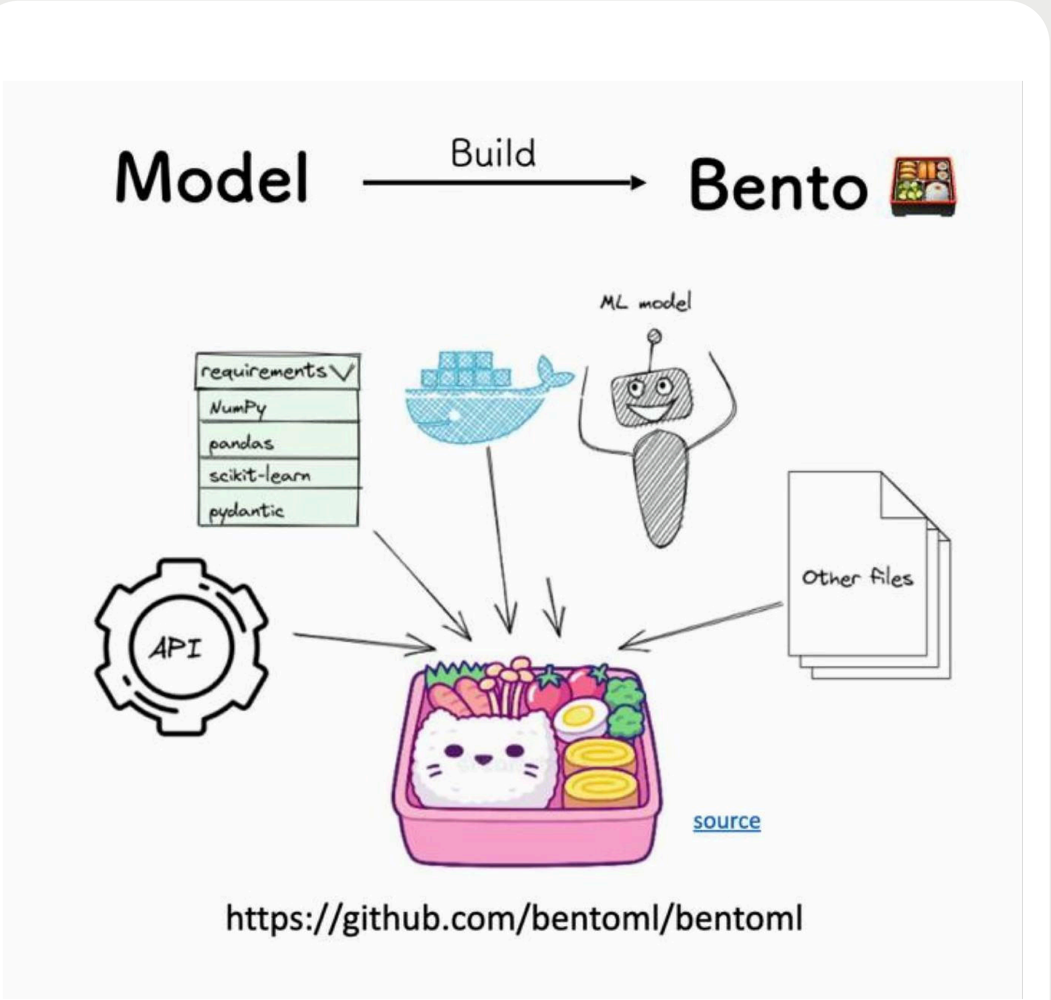

Как результат

- Быстрый сервинг на локальном окружении
- Итоговый контейнер с изоляцией

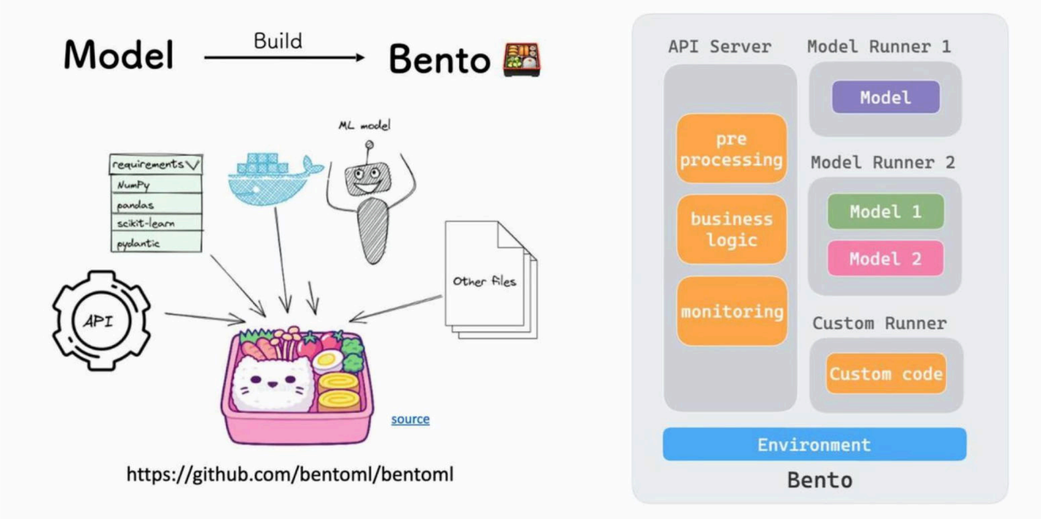

Шаг 1

1. Открываем IDE
2. Создаем виртуальное окружение (python 3.11)
3. Запускаем демон Docker

Шаг 2

1. Клонируем репозиторий с моделью
2. Устанавливаем зависимости
3. Устанавливаем BentoML

И погнали

Итоги встречи

1. Познакомились с сущностью BentoML
2. Оценили его преимущества и ограничения
3. Произвели экспресс упаковку модели и запуск

Computer Vision Rocket

На курсе вы научитесь

1. готовить данные: собирать, устранять ошибки в разметке, мониторить качество
2. отлаживать обучение, находить аномалии и интерпретировать результаты модели
3. работать с metric learning и векторным поиском
4. работать с видео: трекинг и action-recognition
5. предобучать без разметки: от pretext-задач до современных SSL-алгоритмов
6. адаптировать модели детекции, сегментации и OCR под сложные кейсы

Присоединяйтесь со скидкой

Для физических лиц

До 13 марта 18:00 МСК | −15% | До 16 марта | −5% | Старт — 17 марта

142 000 ₽
При полной оплате / предоплате

от 26 520 ₽/мес
При рассрочке на 6 месяцев

Что включено в курс

- 13 лекций и практических заданий
- Проверка заданий от спикеров
- Поддержка в чате и на семинарах со спикерами

159 000 ₽
При полной оплате / предоплате

от 29 693 ₽/мес
При рассрочке на 6 месяцев

Что включено в курс

- 13 лекций и практических заданий
- Проверка заданий от спикеров
- Поддержка в чате и на семинарах со спикерами

168 000 ₽
При полной оплате

от 31 375 ₽/мес
При рассрочке на 6 месяцев

Что включено в курс

- 13 лекций и практических заданий
- Проверка заданий от спикеров
- Поддержка в чате и на семинарах со спикерами

Сайт курса: deepschool.ru/cvrocket-lecture↗

Презентация лекции и репозиторий

Name	Last commit
src	added gitignore
.gitignore	
README.md	
req.txt	

Инференс-сервер своими руками 16

Точки управления

- @bentoml.service
  - Строгая привязка к сервису
  - Управление ресурсами
  - Runtime окружение
- bentofile.yaml
  - От окружения, до системных бибилиотек
  - Фиксирует полную спецификацию для reproducible сборки
- Переменные окружения
  - Разделяет код от конфигурации (API keys, DB URLs, thresholds)

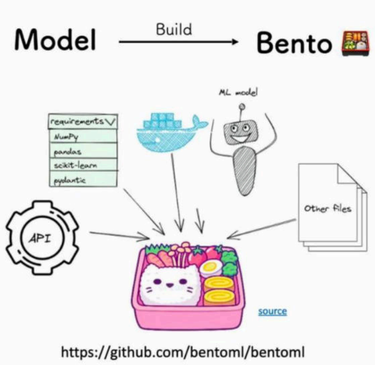

- → презентация лекции
- → репозиторий с кодом

Ответы на вопросы